

# Digitale Harmonie aus historischer Dissonanz

Extraktion, Ordnung und Analyse unstrukturierter Archivdaten des Männerchor Murg

Sven Burkhardt

0009-0001-4954-4426

\* 17-056-912

**i** 15.08.2025





University of Basel Digital Humanities Lab Switzerland

## Abstract

Diese Arbeit befasst sich mit dem Archiv des Männerchor Murg in den Jahren des Zweiten Weltkrieges. Hierfür wird eine automatisierte Pipline auf Basis von LLMs und Patternmatching vorgestellt, mit deren Hilfe Named Entities extrahiert und weiterverarbeitet werden. Ziel ist es, dieses Archiv digital zugänglich zu machen, die beteiligten Personen sowie deren Netzwerke und dessen geographische Ausdehnung sichtbar zu machen.

# Inhaltsverzeichnis

Einleitung							1
Ziel und Relevanz der Arbeit							
Formulierung der Forschungsfrage							
Aufbau der Arbeit							
Geografischer und historischer Kontext		 	•	 			. 1
Quellen							2
Quellentradierung							
Quellenbeschrieb							
Zeitraum							
Dokumententyp							
Inhalt???							
		 	•	 •	•	•	
Korpus							2
Digitalisierung		 		 			. 3
Sichtung & Kategorisierung in Akten							
Transkribtion							
Test mit Tesseract							
Test mit LLM							
Transkribus							
Tagging							
00 0							
Tagging mit Transkribus							
Tagging mit LLM							
Export							
Forschungsstand und Forschungslücke		 	٠	 		•	. 4
Methodenkritik							4
Genutze Tools							
LOD - Linked Open Data							
Protege							
GraphDB							
Msty							
Alphabet – Gemini							
Anthopic – Claude							
OpenAI – ChatGPT							
Transkribus							
Nodegoat							
Netzwerkanalyse als Methode							
Theoretischer Hintergrund der Netzwerkanalyse .							
Ziele der Netzwerkanalyse im Kontext der Quellen							
Technische Umsetzung (Tools, Datenbankstruktur	) .	 		 			. 8
D' l'							0
Pipeline							8
Aufbau XML to JSON Pipeline							
Übersichtsgrafik der Pipeline							
Module im Detail							
document_schemas.py							
initpy							
Person-Matcher		 		 			. 10

Verknüpfung mit externen Quellen (z.B. Wikidata)	29
Analyse der Netzwerke	30
Soziale Netzwerke des Vereinslebens	30
Verbindungen zwischen Mitgliedern	30
Kooperationen mit anderen Vereinen	30
Politische Netzwerke und deren Veränderungen	30
Einfluss der NS-Diktatur auf die Netzwerke	30
Feldpostkarten als Quelle für militärische Netzwerke	30
Geografische Ausdehnung der Netzwerke	30
Einsatzorte der Chormitglieder während des Krieges	
Lokale und überregionale Verbindungen	
Diskussion der Ergebnisse	31
Sichtbarmachung der Netzwerke durch Nodegoat und Netzwerkanalyse	31
Gibt es Veränderungen der Netzwerke im historischen Kontext?	31
Bibliographie	32
References	32

## **Einleitung**

Ziel und Relevanz der Arbeit

Formulierung der Forschungsfrage

Aufbau der Arbeit

Geografischer und historischer Kontext

Die vorliegende Arbeit beschäftigt sich mit Unterlagen aus dem Archiv des "Männerchor Murg" und dessen Nachfolger, den "New Gospelsingers Murg". Murg ist eine Gemeinde am Hochrhein, rund 30 km Luftlinie von Basel entfernt. Der Ort liegt am gleichnamigen Fluss Murg, der in den Rhein mündet. Beide Gewässer bildeten über Jahrhunderte hinweg den wirtschaftlichen Motor der Region: Die Wasserkraft der Murg begünstigte früh die Ansiedlung von Mühlen, Hammerwerken und Schmieden entlang des Bachlaufs. Parallel bot der Rhein mit seiner Drahtseil-Fähre eine wichtige Verkehrs- und Handelsverbindung, und bis zum Ersten Weltkrieg privat betrieben wurde.

Mit dem Ausbau der Landstraße, der heutigen Bundesstraße 34, sowie dem Anschluss an die Bahnstrecke Basel–Konstanz wandelte sich Murg im 19. Jahrhundert von einer landwirtschaftlich geprägten Siedlung zu einer Gewerbe-, Handels- und Industriegemeinde. Während der Industiralisierung mitte des 19. Jahrhunderts wurde die Wasserkraft zu einem entscheidenen Faktor der Region. Die Ansiedlung der Schweizer Textilfirma Hüssy & Künzli AG im Jahr 1853<sup>1</sup> trug trug wesentlich zum Wachstum der Gemeinde bei. Zahlreiche Arbeitskräfte — auch aus der benachbarten Schweiz — machten die Gemeinde zu einem wichtigen Standort der regionalen Textilindustrie. Es waren eben diese schweizer Textilarbeiter, die 1861 den Männechor Murg gründeten, damals unter dem Namen Schweizer Männerchor Murg

<sup>1.</sup> Vgl. Gemeinde Murg, Hrsg., Geschichte Gemeinde Murg

<sup>,</sup> besucht am 29. Juni 2025, https://www.murg.de/seite/33378/geschichte.html.

## Quellen

### Quellentradierung

In den Lagerräumen der New Gospel Singers Murg, dem Nachfolgeverein des Männerchors Murg, wird im Jahr 2018 mehrere je ca. 800 Seiten umfassende Ordner mit historischen Unterlagen gefunden. Für diese Arbeit wird ein Ordner mit der Aufschrift "Männerchor Akten 1925-1944" gewählt, da er neben dem Ordner "Männerchor Akten 1946-1950" den größten Zeitraum abdeckt. Darüberhinaus bietet er das Potential, aufschlussreiche Einblicke in das Vereinsleben in der Zeit vor und während des Nationalsozialismus, insbesondere des Zweiten Weltkrieges, zu geben.

Der Ordner umfasst insgesamt 780 Seiten und deren Inhalt kann als "Protokoll", "Brief", "Postkarte", "Rechnung", "Regierungsdokument", "Noten", "Zeitungsartikel", "Liste", "Notizzettel" oder "Offerte" kategorisiert werden.

### Quellenbeschrieb

#### Zeitraum

blabla

### Dokumententyp

blabla

Inhalt???

## Korpus

Aus dem Bestand des Ordners "Männerchor Akten 1925-1944" werden für diese Arbeit ausschlieslich Akten verwendet, die während des Zweiten Weltkriegs verfasst wurden. Der Analysezeitraum erstreckt sich dementsprehend zwischen dem 01. September 1939 und dem 8. Mai 1945<sup>2</sup>, dem Tag der bedingungslosen Kapitulation Deutschlands.

Diese Begrenzung des zeitlichen Rahmens ist notwendig, um die Funktionaliät der weiter unten beschriebenen Pipeline darstellen zu können. Hieraus ergibt sich in der Folge

<sup>2. [[</sup>vgl.][Finde hier eine Referenz]]keylist

eine Limitation der Anzahl potetieller Akteurinnen und Akteure, Orte und Organisationen. Notwendig ist das besonders mit hinblick auf die Erstellung einer verlässlichen Groundtruth mit angereicherten historischen Daten durch Archivrecherchen. Sie helfen, das Potential solch einer digital unterstützen Arbeitsweise zu unterstreichen.




Abbildung 1: Verteilung der Dokumententypen im untersuchten Bestand (150 Akten - 381 Seiten).

## Digitalisierung

blabla

## Sichtung & Kategorisierung in Akten

blabla

### Transkribtion

blabla

### Test mit Tesseract

blabla

### ${\bf Test\ mit\ LLM}$

blabla

#### Transkribus

blabla

### **Tagging**

blabla

### Tagging mit Transkribus

blabla

### Tagging mit LLM

blabla

### **Export**

blabla

### Forschungsstand und Forschungslücke

Die oben beschriebenen Quellen wurden vor dieser Arbeit bislang nicht wissenschaftlich bearbeitet.

In LOD wird auf Vorprojekte verwiesen. Diese bitte beschreiben (Arcgis und Feldpost)

## Methodenkritik

### Genutze Tools

Digitale Methoden spielen für die Durchführung dieser Arbeit eine zentrale Rolle. Von der Digitalisierung der Quellen über die Transkription bis hin zur Auswertung durchlaufen die Daten zahlreiche Prozessschritte, die mithilfe von Large Language Models, Deep-Learning-Modellen und anderen digitalen Werkzeugen verarbeitet und visualisiert werden. Die Auswahl der Tools orientierte sich dabei an Kriterien wie Verfügbarkeit (Open Source

vs. proprietär), Kompatibilität, Community-Support, erforderlichem Arbeitsaufwand und selbstverständlich dem konkreten Mehrwert für die Forschungsfragen.

In diesem Kapitel werden sowohl Werkzeuge vorgestellt, die tatsächlich eingesetzt wurden, als auch solche, die sich im Verlauf des Projekts als ungeeignet erwiesen. Transparenz ist hierbei ein wesentlicher Aspekt: Ein großer Teil der Methodik entwickelte sich erst im Forschungsprozess selbst. Da sich Large Language Models rasant weiterentwickeln, ist nicht immer von Beginn an klar, ob ein Tool für den eigenen Anwendungsfall geeignet ist. Um diese Unsicherheiten zu dokumentieren, werden hier auch gescheiterte Versuche dargestellt.

### LOD - Linked Open Data

Linked Open Data (LOD) bezeichnet einen dezentral organisierten Ansatz zur Veröffentlichung und Verknüpfung strukturierter Daten im Web. Ziel ist es, Datensätze verschiedener Institutionen und Akteure maschinenlesbar zugänglich zu machen und über standardisierte Formate wie RDF und SPARQL miteinander zu verbinden<sup>3</sup>. Wesentliches Merkmal der LOD-Cloud ist dabei die Nutzung semantischer Beziehungen, insbesondere Äquivalenzen einzelner Daten. Hierfür wird häufig das Prädikat owl:sameAs genutzt, um z.B. mit :Choir owl:sameAs wd:Q131186 eine eigene Instanz als identisch mit der Wikidata-Entität für einen Chor zu deklarieren. Klassen oder Instanzen können so aus unterschiedlichen Datenquellen eindeutig identifiziert und zusammengeführt werden.

Die OWL Web Ontology Language, entwickelt vom World Wide Web Consortium (W3C), ist damit ein zentrales Werkzeug für die Realisierung von LOD.<sup>4</sup> Mit ihr lassen sich Ontologien definieren, die Domänen über Klassen, Individuen und deren Relationen formal beschreiben. Sie ermöglichen, logische Schlussfolgerungen zu ziehen, um verteilte Datenbestände zu verknüpfen und maschinenlesbar auszuwerten. Besonders relevant ist dabei owl:sameAs, das als Identitätsrelation fungiert: Es deklariert Instanzen, die in unter-

<sup>3.</sup> Vgl. Emmanouel Garoufallou und María-Antonia Ovalle-Perandones, Hrsg., Metadata and Semantic Research. 14th International Conference, MTSR 2020, Madrid, Spain, December 2–4, 2020. Revised Selected Papers, Bd. 1355, Communications in Computer and Information Science (Madrid, Spain: Springer Nature Switzerland AG, 2. Dezember 2020

<sup>),</sup> Preface S. VI & S. 13f, ISBN: 978-3-030-71903-6, besucht am 5. Juli 2025, https://basel.swisscovery.org/discovery/openurl?institution= $41SLSP\_UBS\&vid=41SLSP\_UBS:live\&doi=10.1007\%2F978-3-030-71903-6$  30.

<sup>4.</sup> Vgl. "OWL Web Ontology Language Guide", unter Mitarb. von Michael K. Smith, Chris Welty und Deborah L. McGuiness, (Zugriff am besucht am 5. Juli 2025)

<sup>,</sup> besucht am 5. Juli 2025, https://www.w3.org/TR/owl-guide/.

schiedlichen Quellen unter verschiedenen URIs<sup>5</sup> geführt werden, als dasselbe reale Objekt<sup>6</sup> und ermöglicht so eine präzise Zusammenführung von Informationen — ein Grundpfeiler für die Interoperabilität im Semantic Web. Die OWL-Spezifikation baut auf RDF<sup>7</sup> auf und erweitert es um zusätzliche Konzepte. Die Sprache liegt in drei Varianten vor <sup>8</sup>, die sich im Grad ihrer Ausdrucksstärke unterscheiden.<sup>9</sup> Insbesondere OWL DL bietet einen praktikablen Mittelweg zwischen hoher Ausdruckskraft und vollständigem, entscheidbarem Schließen (Reasoning) und ist daher für viele LOD-Anwendungsfälle geeignet.

Trotz ihres Potenzials wird diese Form der Datenverknüpfung bislang jedoch nicht von allen Websites konsequent umgesetzt.<sup>10</sup>.

Ein wichtiger Aspekt dieser Arbeit ist die Unstrukturiertheit relevanter Informationen. Aus diesem Grund wurde auf der Basis der Oben beschrieben Semantik begonnen, eine eigene Ontologie zu entwickeln, die die identifizierten Entitäten systematisch erfasst. Beim Schreiben dieser initialen Ontologie aus rund 2000 Zeilen Code erweist sich schnell ein neues Problem. Die Datengrundlage aus den geschilderten Vorprojekten (siehe Forschungsstand und Forschungslücke)

Mit knapp 1600 Zeilen Code erweist sich diese jedoch als zu aufwendig, sodass der Fokus der Arbeit von der Ontologieentwicklung auf die Extraktion von Entitäten verlagert wurde. Der bestehende Datensatz ist zu klein, um eine umfangreiche Ontologie lohnend zu machen.




Abbildung 2: Ausschnitt der TTL-Ontologie.

Zuverlässige Quellen für Informationen über militärische Einheiten und deren Feldpost-

<sup>5.</sup> Abk. URI; Uniform Resource Identifier

<sup>6.</sup> Vgl. "OWL Guide", 2.3. Data Aggregation and Privacy.

<sup>7.</sup> Abk. RDF; Resource Description Framework

<sup>8.</sup> OWL Lite, OWL DL und OWL Full

<sup>9.</sup> Vgl. "OWL Guide", 1.1. The Species of OWL.

<sup>10.</sup> Vgl. Garoufallou und Ovalle-Perandones, Metadata and Semantic Research, S. 14.

nummern sind das "Forum der Wehrmacht"<sup>11</sup> und der "Suchdienst des DRK"<sup>12</sup>. In beiden Fällen liegen die Daten jedoch nicht als LOD vor, sondern im Forum als einfache Zeichenketten und beim Deutschen Roten Kreuz als OCR-PDF<sup>13</sup> historischer Suchlisten aus der Nachkriegszeit.

Protege

GraphDB

Msty

Alphabet – Gemini

Anthopic – Claude

 ${\bf OpenAI-ChatGPT}$ 

#### Transkribus

Abreviation Tag klappt nicht (wird nicht exportiert) Listen werden nicht exportiert

<sup>11.</sup> Vgl. Andreas Altenburger, "Lexikon der Wehrmacht", (Zugriff am besucht am 15. Januar 2023) , besucht am 15. Januar 2023, https://www.lexikon-der-wehrmacht.de/Gliederungen/Infanteriedivisionen/205ID.htm.

<sup>12.</sup> Vgl. "DRK Suchdienst | Suche per Feldpostnummer", DRK Suchdienst; Suche per Feldpostnummer, unter Mitarb. von Christian Reuter, (Zugriff am besucht am 12. März 2025)

<sup>,</sup> besucht am 12. März 2025, https://vbl.drk-suchdienst.online/Feldpostnummer/FPN.aspx.

<sup>13.</sup> OCR = Optical Character Recognition

### Nodegoat

## Netzwerkanalyse als Methode

Theoretischer Hintergrund der Netzwerkanalyse

Ziele der Netzwerkanalyse im Kontext der Quellen

Technische Umsetzung (Tools, Datenbankstruktur)

# Pipeline

## Aufbau XML to JSON Pipeline

 $\ddot{\mathbf{U}}$ bersichtsgrafik der Pipeline

## Module im Detail

 $document\_schemas.py$ 

\_\_\_init\_\_\_.py





Abbildung 3: Übersicht der gesamten XML-to-JSON-Pipeline

#### Person-Matcher



Oben: Prozess person\_matcher.py
Rechts: Input aus role\_matcher.py und organization\_matcher.py

Abbildung 4: Detailliertes Prozessdiagramm: Personen-Matching

```
place_matcher.py

organization_matcher.py

letter_metadata_matcher.py

type_matcher.py

event_matcher.py

date_matcher.py

Assigned_Roles_Module.py
```

### KEINE AHNUNG WAS DIE HIER MACHEN

validation\_module.py
validation\_module.py
test\_role\_schema.py
llm\_enricher.py
enrich\_pipeline.py

unmatched\_logger.py

## Analyse & Diskussion der Ergebnisse

Visualisierung auf der VM

## Fazit und Ausblick

Zusammenfassung der zentralen Erkenntnisse

Methodische Herausforderungen und Lösungen

Ausblick auf zukünftige Forschung und mögliche Erweiterungen der Datenbank

### ALTER SCHEISS

In Transkribus-Seminaren am Departement Geschichte der Universität Basel wird aus "Männerchor Akten 1925-1944" bereits 2018 und 2022 ein erster Korpus aus 137 Akten<sup>14</sup>. Es entsteht eine Liste, die die Seiten mit deren Lage im Ordner, einem Kurztitel und einem Entstehungsdatum versieht. Als Akte werden im Folgenden Schriftstücke bezeichnet, die entweder durch die Fundsituation, oder ihren Inhalt eindeutig als zusammengehörig betrachtet werden können. So liegt Akte 001 beispielsweise in einer separaten Mappe und umfasst 96 Seiten, während andere Akten nur aus einer einzelnen Seite bestehen können. Während der Fokus 2028 auf den augenscheinlich häufig auftretenden Personennamen "Carl Burger" und "Fritz Jung" liegt, wird 2022 im Rahmen eines zweiten Seminars spezifischer die Feldpost untersucht. Zu diesem Zeitpunkt erfolgt die Transkription mit einem generischen Modell, das nicht auf die unterschiedlichen Handschriften trainiert ist.

### Forschungsstand zu den Quellen

Die vorliegenden Arbeit stützt sich auf diese Vorarbeit, und die darin gesammelten Daten. Beispielsweise werden die Feldpostbriefe um weitere Daten ergänzt. Kernfragen hierfür sind: Welche Einheiten verbergen sich hinter den Feldpostnummern? Wo waren die Einheiten, als der Brief geschrieben werden?

Hierzu werden Nachschlagetabellen in Fachliteratur <sup>15</sup>, die Bestände des Bundesarchives - Militärarchiv Freiburg<sup>16</sup>, des Suchdienstes des Deutschen Roten Kreuzes (DRK)<sup>17</sup>, sowie Citizen Scientist Projekte<sup>18</sup> herangezogen und letztere teils druch eigene Recherche

<sup>14.</sup> Weiterführend vgl. (Sven Burkhardt, "ArcGIS StoryMaps", ArcGIS StoryMaps, [Zugriff am besucht am 12. März 2025]

<sup>,</sup> besucht am 12. März 2025, https://storymaps.arcgis.com)

<sup>15.</sup> vgl.: (Georg Tessin, Verbände und Truppen der deutschen Wehrmacht und Waffen-SS im Zweiten Weltkrieg 1939-1945, Bd. Band 1 - Die Waffengattungen — Gesamtübersicht [Osnabrück: HIBLIO Verlag,

<sup>), (</sup>Christian Hartmann, Wehrmacht im Ostkrieg - Front und militärisches Hinterland 1941/42, 2. Auflage, Bd. 75, Quellen und Darstellungen zur Zeitgeschichte Herausgegeben vom Institut für Zeitgeschichte [München: R. Oldenbourg Verlag, 2010]

<sup>]), (</sup>Christoph Rass und René Rohrkamp, Deutsche Soldaten 1939-1945 Handbuch einer biographischen Datenbank zu Mannschaften und Unteroffizieren von Heer, Luftwaffe und Waffen-SS [Aachen, 2009

<sup>16.</sup> Prof. Dr. Michael Hollmann, "Freiburg", Bundesarchiv Freiburg im Breisgau (Abteilung Militärarchiv), (Zugriff am besucht am 12. März 2025)

<sup>,</sup> besucht am 12. März 2025, https://www.bundesarchiv.de/das-bundesarchiv/standorte/freiburg/.

<sup>17. &</sup>quot;DRK Suchdienst | Suche per Feldpostnummer".

<sup>18.</sup> vgl. Wikidata (Beispiel: ("78th Sturm-Division (Wehrmacht)", unter Mitarb. von Sven Burkhardt, [Zugriff am besucht am 12. März 2025]

<sup>,</sup> besucht am 12. März 2025, https://www.wikidata.org/wiki/Q125489568)),

<sup>(&</sup>quot;Lexikon der Wehrmacht", unter Mitarb. von Andreas Altenburger, [Zugriff am besucht am 12. März

ergänzt.

Für diese Arbeit wird die Kategorisierung von 2018 übernommen und auf den Seiten im Ordner erweitert.  $^{19}$ 

## Beschreibung des Archivbestands

2025]

<sup>,</sup> besucht am 12. März 2025, http://www.lexikonderwehrmacht.de/),

<sup>(&</sup>quot;Forum Geschichte der Wehrmacht", Forum Geschichte der Wehrmacht, unter Mitarb. von Dieter Hermans, [Zugriff am besucht am 12. März 2025]

<sup>,</sup> Forum, besucht am 12. März 2025, https://www.forum-der-wehrmacht.de/)

<sup>19.</sup> Akten\_Gesamtübersicht.csv im Anhang

## Methodischer Zugang

### Digitale Erfassung und Strukturierung der Quellen

### Gliederung in Akten

Die analogen Akten müssen zuerst für die Digitalisierung vorbereitet werden. Sie werden aus den Ordnern genommen und vorsichtig von Heftklammern, Gummibändern und Büroklammern befreit. Dies dient der Konservierung des Papiers – gerade an Stellen, an denen sich vorher Büroklammern befunden haben, frisst sich Rost in das Papier und beschädigt es stark. Auch sonstiger Säurefraß durch nicht-säurefreies Papier, das sich im Ordner befand, zeigt sich an einigen Stellen.

Um schnell und dennoch in guter Auflösung zu digitalisieren, wird die "Dateien"-App<sup>20</sup> von Apple benutzt, da sie gleichzeitig einen grossen Cloud-Speicher und eine OCR-Erkennung bietet. Die Intention dahinter sind schnell durchsuch- und auffindbare Texte. Um die Geschwindigkeit der Digitalisierung zu erhöhen, und eine vergleichbare Qualität zu erhalten, wird ein Ipad mit einem Stativ verwendet, das im 90°Winkel über den Seiten positioniert ist. Die Dateien werden entsprechend der bereits erwähnten Akten\_Gesamtübersicht benannt. Sind mehrere Blätter zusammengeheftet, so ergeben sie eine Akte. Sind sie einzeln, werden sie ebenfalls als einzelne Akte geführt. Die Archivierung findet sowohl analog wie digital auf Seiten-Ebene statt.

#### Digitalisierung und Transkription

### Tagging in Transkribus

Transkribus und seine Modelle unterstützen nicht nur beim Transkribieren der Texte, sondern erlauben auch das Taggen von *Named Entities*. Für die vorliegende Arbeit sind dabei besonders Personen, Orte, Organisationen und Daten relevant. Um hierfür ein stringentes Verfahren zu entwickeln, wurden die Tags wie folgt definiert:

20. vgl. Apple-Finder

#### abbrev

Mit dem Tag abbrev werden alle Abkürzungen getaggt, die für eine eindeutige Entität stehen.

- Beispiel 1: Dr., Prof., St., Hr., Frl., Dipl.-Ing., etc.
- Beispiel 2: Organisationskürzel, wenn sie eindeutig sind:

```
< abbrev > V.D.A. < / abbrev > .
```

Beispiel 3: Falls eine dazugehörige Entität vorhanden ist, wird die Abkürzung getaggt und wird gleichzeitig als zugehörige Entität getaggt:

#### unclear

Mit dem Tag **unclear** werden unleserliche oder schwer entzifferbare Textstellen markiert.

Beispiel 1: Unklare Zeichen oder fehlende Buchstaben:

```
"Er wohnte in<unclear>[...]<unclear>".
```

Beispiel 2: Teilweise lesbare Wörter:

#### sic

Mit dem Tag sic werden Wörter markiert, die im Originaltext in einer falschen oder ungewöhnlichen Schreibweise geschrieben wurden.

Beispiel 1: Veraltete oder falsche Schreibweisen:

```
<sic>da\beta</sic>" für dass.
```

Beispiel 2: Offensichtliche Tippfehler, wenn sie im Originaltext so vorkommen:

"Wir haben <sic>einen</sic> große Freude."

Beispiel 3: Falls eine Korrektur notwendig ist, kann sie als Kommentar ergänzt werden.

<sup>&</sup>quot;<place>Frei<unclear>[...]<unclear><place>".

### Inhaltliche Tags

#### person

Mit dem Tag **person** sollen alle Strings getaggt, die eine direkte Zuordnung einer Person ermöglichen.

- Beispiel 1: Vereinsführer, Alfons, Zimmermann, Alfons Zimmermann, Z. A. Zimmermann, Herr Zimmermann, Herr Alfons Zimmermann, etc.
- Beispiel 2: Funktionen wie Oberlehrer, Chorleiter, etc., wenn Ort, Name oder Organisation bekannt.

Eine Person kann sowohl mit ihrem Namen als auch ihrer Funktion (wie Dirigent) getaggt werden. Aus der Korrespondenz ist in der Regel eine zugehörige Organisation ersichtlich, mit deren Verknüpfung eine namentlich nicht genannte Person identifiziert werden könnte.

#### signature

Mit dem Tag signature werden alle Strings getaggt, die eine handschriftliche Unterschrift darstellen. Der Tag signature ist nahezu deckungsgleich mit dem Tag person. Er dient zur graduellen Unterscheidung, ob ein Name im Fließtext als gesichert leserlich oder handschriftlich als Signatur vorliegt.

Beispiel 1: Eindeutig lesbare Signaturen werden direkt getaggt:

<signature>A. Zimmermann</signature>.

Beispiel 2: Teilweise unleserliche Signaturen werden mit dem Tag unclear innerhalb von signature markiert:

<signature>R. We<unclear>[...]</unclear></signature>.

Beispiel 3: Wenn nur ein Teil des Namens lesbar ist, aber eine Identifikation unsicher bleibt, sollte die Unterschrift vollständig im Tag unclear innerhalb von signature stehen:

<signature><unclear>Unleserlich</unclear></signature>.

🖼 Beispiel 4: Wenn eine Signatur einer bekannten Person zugeordnet werden

kann, aber nicht vollständig lesbar ist, bleibt die Signatur erhalten und wird **ohne** den Tag **person** zu verwenden:

<signature>A. Zimm<unclear>[...]</unclear></signature>.

Beispiel 5: Wenn eine Unterschrift vollständig transkribiert wurde und die Person bekannt ist, wird sie nur mit signature getaggt, ohne den Tag person zu verwenden: <signature>Alfons Zimmermann</signature>.

### organization

Mit dem Tag organization werden alle Strings getaggt, die eine direkte Zuordnung einer Organisation ermöglichen.

Beispiel 1: Männerchor Murg, Verein Deutscher Arbeiter (V.D.A.), Murgtalschule, etc.

Beispiel 2: Abkürzungen, wenn sie eine Organisation eindeutig bezeichnen, z.B. V.D.A., NSDAP, STAGMA, etc.

#### place

Mit dem Tag place werden alle Strings getaggt, die sich auf einen geografischen Ort beziehen.

Beispiel 1: Murg (Baden), Freiburg, Berlin, Murgtal, Schwarzwald, etc.

Beispiel 2: Orte mit näherer Bestimmung, z.B. "bei Berlin", "im Murgtal" werden getaggt:

<place>im Murgtal</place>.

#### date

Mit dem Tag date werden alle expliziten und implizierten Datumsangaben markiert.

**■ Beispiel 1**: 29.05.1936

**■ Beispiel 2**: 29. Mai 1936

Beispiel 3: den 29. d. Mts.:

<date when="29.05.1936 ">den 2.</date> <abbrev>d. Mts.</abbrev>

#### event

Mit dem Tag **event** werden expliziten und implizierten Ereignisse markiert. Diese Ereignisse haben einen zeitlichen oder räumlichen Bezug, und können benannt werden. Dazu zählen:

- **Beispiel 1**: "Jubiläumskonzert"
- Beispiel 2 "Gründung des Vereins"
- ™ Beispiel 2"Kriegsausbruch" oder "Kriegsende"

Konzepte, die nicht klar in den Texten benannt werden, wie beispielsweise die Suche nach einem Dirigenten, können nicht immer Ereignis getaggt werden. Sie sollen später aber in der Datenbank implementiert werden.

### Strukturelle Tags

#### abbrev

Mit dem Tag abbrev werden alle Abkürzungen getaggt, die für eine eindeutige Entität stehen.

- Beispiel 1: Dr., Prof., St., Hr., Frl., Dipl.-Ing., etc.
- Beispiel 2: Organisationskürzel, wenn sie eindeutig sind:

< abbrev > V.D.A. < /abbrev > .

Beispiel 3: Falls eine dazugehörige Entität vorhanden ist, wird die Abkürzung getaggt und wird gleichzeitig als zugehörige Entität getaggt:

<person><abbrev>Dr.</abbrev>Weiß</person>

#### unclear

Mit dem Tag unclear werden unleserliche oder schwer entzifferbare Textstellen markiert.

Beispiel 1: Unklare Zeichen oder fehlende Buchstaben:

"Er wohnte in<unclear>[...]<unclear>".

Beispiel 2: Teilweise lesbare Wörter:

"<place>Frei<unclear>[...]<unclear><place>".

#### sic

Mit dem Tag sic werden Wörter markiert, die im Originaltext in einer falschen oder ungewöhnlichen Schreibweise geschrieben wurden.

Beispiel 1: Veraltete oder falsche Schreibweisen:

```
"<sic>daß</sic>" für dass.
```

Beispiel 2: Offensichtliche Tippfehler, wenn sie im Originaltext so vorkommen:

"Wir haben <sic>einen</sic> große Freude."

Beispiel 3: Falls eine Korrektur notwendig ist, kann sie als Kommentar ergänzt werden.

### Digitalisierungsprozess und Herausforderungen

Hier gehört dringend dazu, dass die Quellen über einen längeren Zeitraum digitalisiert wurden. Das bedeutet, dass sich die Kameras geändert haben. Verwendet wurden primär ein IPad Pro 2nd Generation (2017) und ein IPad Air 4th Generation (2022). Die Verwendete Software ist die Scan-Funktion von Apple ICloud. Die Auswahl der Software war aus rein ökonomischen Gründen. Da das Digitalisierungsprojekt bereits 2018 begonen wurde, fehlten weitestgehend Grundlagenkenntnisse, die im Digital Humanities Studium vermittelt wurden. Berücksichtigt wurden jedoch einige Richtlinien, wie sie in den Archiv-Kursen des Bachelor-Geschichtsstudiums vermittelt wurden (gleichbleibende Beleuchtung, Hintergrund). Die Scanqualität ist daher oft nicht optimal, was zu problemen bei der OCR Erkennung mit OCR Software (Apple OCR, Adobe, etc.) führte. Aus diesem Grund wurden 75 Akten zunächst mit dem Model "The German Giant I" mit einer CER von 8,30% transkribiert. Mit insgesammt 4 Iterationen wurde eine Groundtruth für ein eigenes Modell erstellt, und gleichzeitig Personen, Orte, Daten und Organisationen getaggt. Hierzu wurde auch manuell OpenAIs CHatGPT 40 Modell verwendet, das für die Rechtschreibprüfung verwendet wurde. Tauchte ein Rechtschreibfehler im Text auf, wurde dieser manuell überprüft. War der Fehler bereits im Ursprungstext, so wurde der Tag "sic" verwendet, und eine Korrektur beigefügt.

Die so erstellten 70 Akten ergaben 158 Seiten zu insgesammt 22.155 Wörtern Groundtruth, womit dann ein eigenes Transkribus Modell<sup>21</sup> (ModelID: 287793) erstellt wurde. Es erreichte eine Accuracy (CER) von 6,58%. Später wurden die verbleibenden 80 Akten nur noch mit diesem Modell transkribiert.

### ChatGPT produziert daraus:

Durch CHatGPT verliert der Text zwar seine ursprüngliche Formatierung und Zeilenumbrüche, aber wird nun nahezu fehlerfrei lesbar. Nur das "Venstadler Liedchen" ist eigendlich eines aus "Neustadt". Eine anschliessende menschliche Korrektur ermöglicht also den Abgeleich mit dem nun lesbaren Text, und die Korrektur der Transkribtion.

Korrigiert und getagt lautet der Brief nun:

```
München, 28.V.1941
Lieber Otto!
Nur wer die Sehnsucht kennt weiß was ich leide
Ich wandle traurig her in schwarzer Seide.
Die Sehnsucht brennt, du bist so fern.
Ach lieber Otto, wie hab ich dich gern.
Ich schnitt es gern in alle Rinden.
Ach Otto, wann u. wo kann ich dich finden?
Deine dich nie vergessende
Lina Fingerdick
An
Herrn Otto Bollinger
z.Hd. Herrn Alfons Zimmermann
Vereinsführer des Männerchor
Murg
Laufenburg (Baden)
Rhina
```

<sup>21.</sup> burkhardt\_transkribus\_nodate.

Mung, 15. ang. 41. Main linker Alfons. that winder insmal sin Lindsfor gir fiften. und kum mir dir gaspige Galagan sich guspand. Int praint arvgungand Fust um den Mainnechen Seistadt inn dan Vill. Das Lindsfan Jer usfullen, son fix ginn Abssir um Beiler fungen " wief Hindropper" Cherroft if Fani = muck brilingto, kin Controval. Visland Anitarfin filmer Hital giv nafulter.

Dritarfin filmer if Sul Lind now

, Deel wilden Lind" now larry. Kirchl El sounder 1928 um 10. Pailed. Sangert . Poff wew Ingriffingbuland in Bin gapingen ind worthold ubsound großen Brifull. Giff pfrons Soil Righiga gir finden. Also Ulow: guraft Sul Veisladen Tinden. william Let Cleaner Linkfor wind some Landal imminglish, Sum foris Wall. Chi fugl Gonfor Carl

Abbildung 5: Beispiel für handschriftlichen Text in Akte\_076 erkannt mit Transkribus

# Murg. 15. Aug 41

Mein lieber Alfons! Sehen lunge Lreitt es mich dem Männerchor wieder einmal ein Liedehen zu stehten. und kam mir die gestege Gelegenheit gussend. Männechor Venstad um den Title das Liedchen zu erhalten, wo sie zum Abschied am Aute sängen "auf Wiederschen Owohl ich Frei! märke beifügte, keine Aentwarb. Vielleicht gelingt es Dir diesen Iitel zu erhalten. Weiterhin sänge ich fal Lied nur "Bas alte Lied von being. Rerohl Es wurde 1928 am 10. Dachub. Sängerb. Frst von Begrüßungsabend in Dien gesungen. und erntete überaus großen Reifall. Es ich schwer das Richtige zu finden. Aler Alfon, werst das Vemsladler Liedchen. alsdann das Biener Lidchen und wenn Leides unmöglich, dann freu Nall. Mit herzl. Grüße Dein Carl

Abbildung 6: Transkription von Abbildung 5

Murg, 15. Aug. 41

Mein lieber Alfons!

Schon lange treibt es mich, dem Männerchor wieder einmal ein Liedchen zu stiften, und kam mir die günstige Gelegenheit gelegen.

Ich schrieb vergangenes Jahr an den Männerchor Venstad, um den Titel des Liedchens zu erhalten, das sie zum Abschied am Auto sangen: "Auf Wiedersehen, o wohl ich frei!"

Ich fügte eine Frankierung bei, erhielt jedoch keine Antwort. Vielleicht gelingt es Dir, diesen Titel zu erhalten.

Weiterhin sang ich das Lied nur "Das alte Lied von Wien". Obwohl es am 10. Dezember 1928 beim Sängerbund-Fest von Begrüßungsabend in Wien gesungen wurde und überaus großen Beifall erntete, ist es schwer, das Richtige zu finden.

Aber Alfons, zuerst das Venstadler Liedchen, dann das Wiener Liedchen und wenn beides unmöglich, dann Fröhlichsein.

Mit herzlichen Grüßen

Dein


Carl


Abbildung 7: Transkription durch ChatGPT von Abbildung 6

```
Murg . 15. Aug 41
Mein lieber Alfons!
Seit langem treibt es mich dem Männer-
chor wieder einmal ein Liedchen zu stiften.
und kam mir die günstige Gelegenheit passend.
Ich schrieb vergangenes Jahr an den
Männechor Vorstand um den Titel das Liedchen
zu erhalten, wo sie zum Abschied am Auto
sangen "auf Wiederschen" Obwohl ich Frank-
marke beifügte, keine Antwort. Vielleicht
gelingt es Dir diesen Titel zu erhalten.
Weiterhin sänge ich das Lied nur
"Das alte Lied" von Komp. Kirchl
Es wurde 1928 am 10. Deutsch. Sängerb. Fest
am Begrüßungsabend in Wien gesungen.
und erntete überaus großen Beifall.
Es ich schwer das Richtige zu finden.
Also Alfons! zuerst das Neustadter Liedchen.
alsdann das Wiener Liedchen und wenn
Beides unmöglich, dann freie Wahl.
Mit herzl. Grüßen
Dein
Carl
```

Abbildung 8: Tagging von Abbildung 7

## Diagram english





Top: process in person\_matcher.py

Right: input from role\_matcher.py and organization\_matcher.py

Gründe für den Wechsel zu Nodegoat

Nodegoat Modelierung

### Netzwerkanalyse als Methode

Theoretischer Hintergrund der Netzwerkanalyse

Ziele der Netzwerkanalyse im Kontext der Quellen

Technische Umsetzung (Tools, Datenbankstruktur)

### Normalisierung der Dateien — von PDF zu JPEG

```
import os
1
    import fitz # PyMuPDF
2
3
    def convert_pdf_to_jpg(src_folder, dest_folder):
4
        # Überprüfen, ob der Zielordner existiert, und ihn ggf. erstellen
        if not os.path.exists(dest_folder):
6
            os.makedirs(dest_folder)
8
        # Durchgehen durch alle Dateien im Quellordner
9
        for root, dirs, files in os.walk(src_folder):
10
            for file in files:
11
                 # Überprüfen, ob die Datei eine PDF-Datei ist
12
                 if file.lower().endswith(".pdf"):
                     # Vollständigen Pfad zur PDF-Datei erstellen
14
                     pdf_path = os.path.join(root, file)
15
                     # PDF-Datei öffnen
16
                     doc = fitz.open(pdf_path)
17
                     # Durch alle Seiten der PDF-Datei gehen
18
                     for page_num in range(len(doc)):
19
                         page = doc[page_num]
20
                         # Seite in ein PixMap-Objekt umwandeln (für die Konvertierung in
21
                         \hookrightarrow JPG)
                         pix = page.get_pixmap()
22
                         # Dateinamen ohne Dateiendung extrahieren
23
                         filename_without_extension = os.path.splitext(file)[0]
24
                         # Ausgabedateinamen erstellen mit führenden Nullen für die
25
                         # Seitennummer
26
                         output_filename = f"{filename_without_extension}_S{page_num +
27
                         → 1:03d}.jpg"
28
29
                         # Vollständigen Pfad zur Ausgabedatei erstellen
30
                         output_path = os.path.join(dest_folder, output_filename)
31
                         # Bild speichern
32
```

```
pix.save(output_path)
33
                        # PDF-Datei schließen
34
                       doc.close()
35
36
                        # Erfolgsmeldung ausgeben
37
                        \verb|print(f"{file}| wurde erfolgreich umgewandelt und gespeichert|\\
38
                       in {dest_folder}")
39
     # Pfade zu den Ordnern mit den PDF-Dateien (Quelle) und den JPG-Dateien (Ziel)
41
     src_folder = r"/Users/svenburkhardt/Documents/D_Murger_Männer_Chor_Forschung/Scan_Mä |
42
     \rightarrow \quad nnerchor/\texttt{M\"{a}}nnerchor\_\texttt{Akten\_1925-1945/Scan\_M\"{a}}nnerchor\_\texttt{PDF"}
     dest_folder = r"/Users/svenburkhardt/Documents/D_Murger_Männer_Chor_Forschung/Master |
43
     \rightarrow \quad \texttt{arbeit/JPEG\_Akten\_Scans"}
44
45
46
     \# Funktion aufrufen, um die Konvertierung durchzuführen
     convert_pdf_to_jpg(src_folder, dest_folder)
48
```

## Aufbau der Datenbank

## Konzeption der Datenmodelieung

Eigene Ontologie im Vergleich zu bestehenden Standards

Verknüpfung von Personen, Orten und Ereignissen

## Implementierung der Datenbank

Datenbankdesign

Herausforderungen bei der Datenaufnahme

Verknüpfung mit externen Quellen (z.B. Wikidata)

## Analyse der Netzwerke

Soziale Netzwerke des Vereinslebens

Verbindungen zwischen Mitgliedern

Kooperationen mit anderen Vereinen

Politische Netzwerke und deren Veränderungen

Einfluss der NS-Diktatur auf die Netzwerke

Feldpostkarten als Quelle für militärische Netzwerke

Geografische Ausdehnung der Netzwerke

Einsatzorte der Chormitglieder während des Krieges

Lokale und überregionale Verbindungen

# Diskussion der Ergebnisse

Sichtbarmachung der Netzwerke durch Nodegoat und Netzwerkanalyse

Gibt es Veränderungen der Netzwerke im historischen Kontext?

## Bibliographie

Referenzen, die noch nachzuschauen sind:

– Akten\_Gesamtübersicht.csv im Anhang

## References

- "78th Sturm-Division (Wehrmacht)". Unter Mitarbeit von Sven Burkhardt, (Zugriff am besucht am 12. März 2025)
  - . Besucht am 12. März 2025. https://www.wikidata.org/wiki/Q125489568.
- Altenburger, Andreas. "Lexikon der Wehrmacht", (Zugriff am besucht am 15. Januar 2023)
  - . Besucht am 15. Januar 2023. https://www.lexikon-der-wehrmacht.de/Gliederunge n/Infanteriedivisionen/205 ID.htm.
- Burkhardt, Sven. "ArcGIS StoryMaps". ArcGIS StoryMaps, (Zugriff am besucht am 12. März 2025)
  - . Besucht am 12. März 2025. https://storymaps.arcgis.com.
- "DRK Suchdienst | Suche per Feldpostnummer". DRK Suchdienst; Suche per Feldpostnummer. Unter Mitarbeit von Christian Reuter, (Zugriff am besucht am 12. März 2025)
  - . Besucht am 12. März 2025. https://vbl.drk-suchdienst.online/Feldpostnummer/FPN.aspx.
- "Forum Geschichte der Wehrmacht". Forum Geschichte der Wehrmacht. Unter Mitarbeit von Dieter Hermans, (Zugriff am besucht am 12. März 2025)
  - . Forum. Besucht am 12. März 2025. https://www.forum-der-wehrmacht.de/.
- Garoufallou, Emmanouel und María-Antonia Ovalle-Perandones, Hrsg. Metadata and Semantic Research. 14th International Conference, MTSR 2020, Madrid, Spain, December 2–4, 2020. Revised Selected Papers. Bd. 1355. Communications in Computer and Information Science. Madrid, Spain: Springer Nature Switzerland AG, 2. Dezember 2020

- . ISBN: 978-3-030-71903-6, be sucht am 5. Juli 2025. https://basel.swisscovery.org/discovery/openurl?institution=41 SLSP\_UBS&vid=41 SLSP\_UBS:live&doi=10.1007 %2 F978-3-030-71903-6\_30.
- Gemeinde Murg, Hrsg. Geschichte Gemeinde Murg
  - . Besucht am 29. Juni 2025. https://www.murg.de/seite/33378/geschichte.html.
- Hartmann, Christian. Wehrmacht im Ostkrieg Front und militärisches Hinterland 1941/42. 2. Auflage. Bd. 75. Quellen und Darstellungen zur Zeitgeschichte Herausgegeben vom Institut für Zeitgeschichte. München: R. Oldenbourg Verlag, 2010
- Hollmann, Prof. Dr. Michael. "Freiburg". Bundesarchiv Freiburg im Breisgau (Abteilung Militärarchiv), (Zugriff am besucht am 12. März 2025)
  - . Besucht am 12. März 2025. https://www.bundesarchiv.de/das-bundesarchiv/standorte/freiburg/.
- "Lexikon der Wehrmacht". Unter Mitarbeit von Andreas Altenburger, (Zugriff am besucht am 12. März 2025)
  - . Besucht am 12. März 2025. http://www.lexikonderwehrmacht.de/.
- "OWL Web Ontology Language Guide". Unter Mitarbeit von Michael K. Smith, Chris Welty und Deborah L. McGuiness, (Zugriff am besucht am 5. Juli 2025)
  - . Besucht am 5. Juli 2025. https://www.w3.org/TR/owl-guide/.
- Rass, Christoph und René Rohrkamp. Deutsche Soldaten 1939-1945 Handbuch einer biographischen Datenbank zu Mannschaften und Unteroffizieren von Heer, Luftwaffe und Waffen-SS. Aachen, 2009

Tessin, Georg. Verbände und Truppen der deutschen Wehrmacht und Waffen-SS im Zweiten Weltkrieg 1939-1945. Bd. Band 1 - Die Waffengattungen — Gesamtübersicht. Osnabrück: HIBLIO Verlag, 1977

.